Politechnika Wrocławska

Systemy operacyjne 2

Laboratorium nr 7

Wyrażenia regularne

Szymon Datko

szymon.datko@pwr.edu.pl

Wydział Informatyki i Telekomunikacji,

Politechnika Wrocławska

semestr letni 2021/2022

HR EXCELLENCE IN RESEARCH

W skrócie

- Odnajdywanie ciągów znaków o określonej strukturze w dużym tekście.

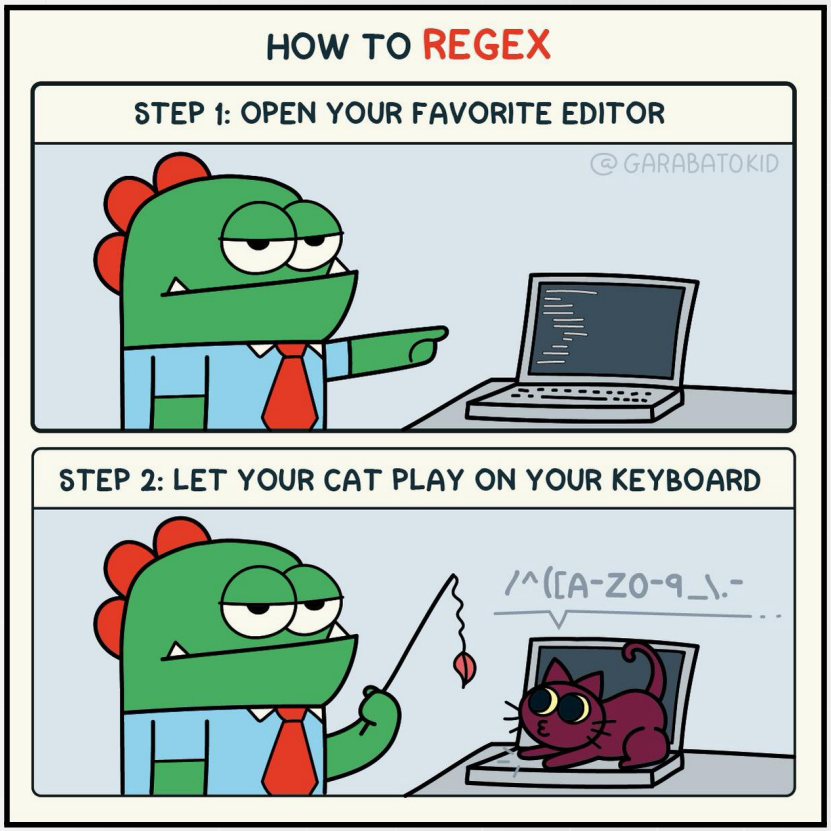

Uwaga!

- Aby wykonać te zajęcia, należy upewnić się, że w systemie zainstalowana jest odpowiednia implementacja programu `awk` – o nazwie `gawk` (GNU `awk`).
- Domyślnie może być zainstalowana implementacja, która nie obsługuje poprawnie wszystkich wyrażeń regularnych – na przykład `mawk` (unikać!).

Źródło obrazka: https://medium.com/@leerbardon/regular-expressions-c174ce78029f

Politechnika Wrocławska

Część I

Omówienie zagadnień

Politechnika Wrocławska

Wyrażenia regularne

- Narzędzie pozwalające odnaleźć łańcuchy znaków, pasujące do wzorca.
- Wzorzec do znalezienia może stanowić pojedyncza litera lub zwykły napis.
  - Oprócz tego dostępny jest szereg rozbudowanych operatorów i symboli.
    - Definiowanie alternatywnych fragmentów (tj. A lub B).
    - Ograniczenie zakresu znaków w danym łańcuchu (np. małe litery).
    - Określenie krotności wystąpień jakiegoś wyrażenia (np. **trzy** cyfry).
    - Sprecyzowanie położenia fragmentu (względem początku/końca...).
  - Bardzo przydatny jest też mechanizm grupowania i wstecznych referencji.
    - Pozwala użyć wcześniej dopasowanego łańcucha jako części wzorca.
    - Praktyczny przykład: odnalezienie znacznika zamykającego w XML.
- Nie ma jednej jedynej rodziny wyrażeń regularnych.
  - Składnia większości zapisów działa mimo to zazwyczaj podobnie.
  - Różne narzędzia mogą implementować specjalne wzorce w inny sposób.
  - Powszechnie stosowane jest **PCRE** – Perl Compatible Regular Expressions.
  - https://unix.stackexchange.com/questions/119905/why-does-my-regular-expression-work-in-x-but-not-in-y
- Abstrahujemy tutaj od informatyki teoretycznej i gramatyki formalnej.

Kiedy stosować? – dygresja

„lol, it works :DD” – *zerni* said on *06/12/05 15:40:06*

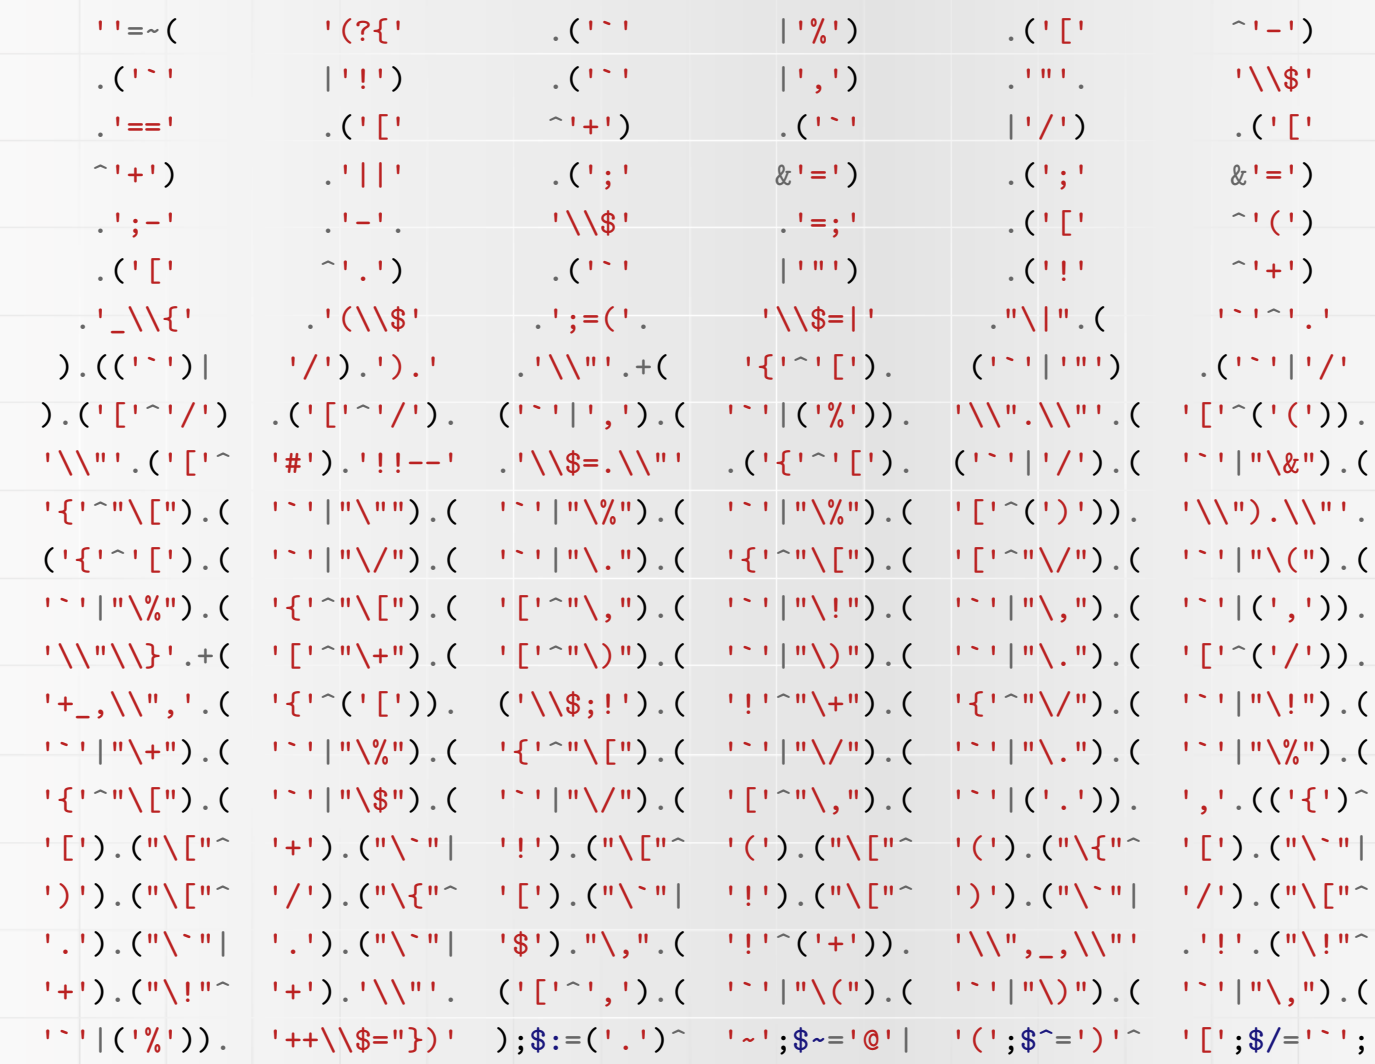

Źródło: http://99-bottles-of-beer.net/language-perl-737.html

Podstawowe operatory i wyrażenia

- `a` – proste dopasowanie pojedynczego znaku (symbolu).
  - Szukamy czy w podanym łańcuchu znajduje się litera `a`.
- `abc` – proste dopasowanie łańcucha znak po znaku.
  - Szukamy fragmentu łańcucha, rozpoczynającego się od litery `a`.
  - Następnie musi znaleźć się litera `b`, a za nią litera `c`.
  - Można to interpretować, jako logiczną koniunkcję kolejnych wyrażeń (AND).
- `ab|cde` – alternatywa, dopasowanie łańcucha `ab` lub `cde`.
  - Koniunkcja (AND) wiąże silniej, niż alternatywa (OR – operator `|`).
  - Jest to co samo co zapisanie `(ab)|(cde)`.
- `a(b|c)de` – nawiasy umożliwiają grupowanie fragmentów wyrażeń.
  - Szukamy łańcucha, rozpoczynającego się od litery `a`.
  - Następnie musi wystąpić litera `b` lub litera `c`.
  - Dalej musi znaleźć się litera `d`, a za nią litera `e`.

Określenie zakresu znaków

- `[abc]` – ustalenie zakresu dopuszczalnych znaków na danej pozycji.
  - W tym miejscu może wystąpić litera `a`, litera `b` lub litera `c`.
  - Poniekąd jest to analogiczne do zapisu `a|b|c`.
  - Kolejność i powtórzenia podanych znaków nie mają znaczenia.
    - Zapis `[abbbaa]` oznacza dokładnie to samo, co `[ab]`.
  - Przy pomocy znaku `-` (minus) można określić przedział znaków.
    - `[a-z]` to dopuszcza pojedynczą małą literę.
    - `[0-9]` to pojedyncza cyfra.
    - `[a-zA-Z0-9_-]` obejmuje małe i duże litery, cyfry oraz znaki `_` i `-`.
    - **Uwaga!** Zakres `[a-z]` często nie obejmuje znaków typu ą, ę, ó, itd.
  - W operatorze `[]` większość znaków specjalnych traci swoje znaczenie.
    - Na przykład `.`, `*`, `(` i `)` to po prostu kropka, gwiazdka i nawiasy.
- `[^abc]` – odwrotność `[abc]`, zakres **nie**dopuszczalnych znaków.
  - W tym miejscu może wystąpić dowolny znak, inny niż litera `a`, `b` lub `c`.
  - Ustawienie znaku `^` w innym miejscu wyłącza to specjalne zachowanie.
    - Czyli `[a^bc]` dopuszcza jeden z czterech znaków: `a`, `b`, `c` oraz `^`.

Ustalenie liczby powtórzeń symbolu

- Podane tu operatory odnoszą się do poprzedzającego je symbolu/grupy.
- `a{3}` – dokładnie 3 wystąpienia znaku `a`.
  - Odpowiednik zapisu `aaa`.
- `[abc]{2,4}` – od 2 do 4 wystąpień znaków z zakresu `[a-c]`.
  - Odpowiednik `[abc][abc]|[abc][abc][abc]|[abc][abc][abc][abc]`.
- `a(bc)?` – oznaczenie opcjonalności, grupa `bc` może wystąpić 0 lub 1 razy.
  - Czyli pasującym fragmentem będzie napis `a` oraz `abc`.
- `[A-Z]-[0-9]+` – co najmniej jedna cyfra po dużej literze i znaku minusa.
  - W ten sposób można dopasować oznaczenia budynków naszej Uczelni.
- `a(bc)*` – dowolna liczba wystąpień (0 lub więcej) ciągu `bc` po literze `a`.
  - Pasujące napisy: `a`, `abc`, `abcbc`, `abcbcbc`; ale nie: `ab`, `abcb`, `abcbcc`.
  - Standardowo silniki usiłują znaleźć najdłuższe możliwe dopasowanie.
  - Dygresja – należy przemyśleć i unikać zapisów typu `(ab*)(b*)`!

Inne przydatne symbole i zapisy

- `.` – dowolny pojedynczy znak.
- `^` – początek przetwarzanego łańcucha.
  - Zwykle jest to po prostu początek linii (gdy przetwarzamy wiersze).
  - Na przykład `^[0-9]` dopasuje linie, rozpoczynające się od dowolnej cyfry.
- `$` – koniec przetwarzajanego łańcucha.
  - Zwykle jest to po prostu koniec linii (gdy przetwarzamy wiersze).
    - W tym wypadku ostatnim znakiem **nie** jest znak nowej linii `\n`.
  - Zapis `a$` może dopasować więc linię, której ostatnim znakiem jest litera `a`.
- Sekwencja ucieczki `\` pozwala wyłączyć specjalnie znaczenie znaków.
  - Zapis `\*` oznacza wtedy to samo co `[*]`.
  - Analogicznie `[\[\]]` pozwala dopasować pojedynczy znak `[` lub `]`.
- Wiele implementacji wspiera też określenie klas znaków w operatorze `[]`.
  - Lista: https://www.gnu.org/software/gawk/manual/html_node/Bracket-Expressions.html
  - Na przykład `[:lower:]` to to samo co `a-z`, ale może być czytelniejsze.
  - **Uwaga!** Użycie wygląda wtedy następująco w zapisie: `[[:lower:]]`.

Politechnika Wrocławska

Stosowanie w typowych narzędziach

- Narzędzia `grep`, `sed` i `vi` używają wariantu Basic Regular Expressions.
  - Główna różnica polega na tym, że część operatorów wymaga dodania `\`.
  - Na przykład `\(...\)`, `\{...\}`, `\|`, `\?`, `\+` zamiast `(...)`, `{...}`, `|`, `?`, `+`.
    - Jak na ironię, zapisy `.`, `*`, `^`, `$`, `[...]` pozostają bez zmian!
- Narzędzia `awk`, `grep -E` i `sed -E` używają Extended Regular Expressions.
  - Obejmują one zapisy, które zostały omówione na poprzednich slajdach.
- Narzędzie `grep -P` i wiele języków programowania obsługuje PCRE.
  - Obejmuje on szereg zaawansowanych mechanizmów, nieumówionych tu.
- W powłokach ścieżki dopasowanie są za pomocą mechanizmu `glob`.
  - Znaczenie części symboli w tym mechanizmie różni się od tu omawianych.
  - Niektóre powłoki oferują także rozszerzenia w tym temacie, np. `extglob`.
  - W powłoce **Bash** występuje operator `=~`, implementujący wariant ERE.
    - On akurat nie służy do dopasowywania ścieżek...
    - Stosowany jest do porównywania ciągów w konstrukcji `[[ ... ]]`.

Użycie w programie awk

- Opcja `--re-interval`, aby działał operator określenia powtórzeń `{}`.
- Definiowanie separatorów.
  - Zawartość zmiennych `RS` i `FS` stanowi wyrażenie regularne.
  - Pozwala to elastycznie je definiować, np. domyślne `FS = "[ \t\n]+"`.
- Wzorce: `/wyrażenie/` lub `zmienna ~ /wyrażenie/`
  - Akcje zostaną wykonane, jeśli rekord lub `zmienna` pasuje do wyrażenia.
  - Na przykład `/^$/ { ILE += 1 }` pozwala zliczyć puste rekordy.
- Funkcje do manipulacji na łańcuchach znaków.
  - `match(łańcuch, wyrażenie, tablica)`
    - Zwraca pozycję pierwszego pasującego znaku w łańcuchu, lub zero.
    - Opcjonalny argument `tablica` przechowa dopasowany ciąg/grupy.
  - `sub(wyrażenie, zamiennik, cel)`
  - `gsub(wyrażenie, zamiennik, cel)`
    - Zamienia pasujący fragment tekstu w zmiennej `cel` (domyślnie `$0`).
    - Zwraca liczbę zmian – 0 lub 1 w `sub()`; 0 lub więcej w `gsub()`.
  - Więcej: https://www.gnu.org/software/gawk/manual/html_node/String-Functions.html

Politechnika Wrocławska

Narzędzia przydatne przy nauce i pracy

- https://regexone.com
  - Świetne, praktyczne i interaktywne, wprowadzenie do wyrażeń regularnych.
- https://regex101.com
  - Chyba najlepsze narzędzie do sprawdzania działania wyrażeń regularnych.
  - Na bieżąco wskazuje co zostało dopasowane i tłumaczy dlaczego.
  - Wspiera wiele wariantów / silników wyrażeń.
- https://regexr.com
  - Trochę inne, ale wciąż bardzo dobre narzędzie do testowania wyrażeń.
- Porównanie narzędzi: https://regexland.com/comparison-regex-testers/

Politechnika Wrocławska

Część dla dociekliwych

Zadanie dodatkowe

Zadanie domowe

Monstrum, albo funkcji opisanie.

„Zaprawdę, nie masz nic wstrętniejszego ponad monstra owe, naturze przeciwne, funkcjami zwane, bo są to płody plugawego skrypciarstwa i diabelstwa. Są to zapisy bez cnoty, właściciela i uprawnień, istne stwory piekielne, do błędów jedynie zdatne. Nie masz dla takich jak oni między skryptami poczciwymi miejsca. A owo `.bashrc`*, gdzie ci bezecni się gnieżdżą, gdzie ohydnych swych definicji dokonują, starte być musi z powierzchni dysku, a ślad po nim solą i* `shred`*em posypany."*

Proszę omówić stosowanie funkcji w skryptach powłoki – jak je definiować, wywoływać i przekazywać do nich parametry oraz w jaki sposób można zwracać wyniki z funkcji. Czy można jakoś upewnić się, że jakaś funkcja jest zdefiniowana i ewentualnie wczytać ją z osobnego pliku? Jak usunąć zdefiniowaną funkcję? Czy mogą istnieć dwie funkcje o tej samej nazwie, ale różnej liczbie argumentów?